Литературный обзор

Содержание

1. Введение в обзор
2. Нейросетевые подходы в ценообразовании опционов
   2.1. *Ранние работы (Malliaris & Salchenberger, 1993; Hutchinson et al., 1994)*
   2.2. *Современные обзоры (Liu et al., 2019)*
   2.3. *Применение глубокого обучения (Schmidhuber, 2015)*
3. Архитектуры нейросетей, релевантные для задачи
   3.1. *Maxout Networks (Goodfellow et al., 2013) — обоснование использования maxout-слоёв*
   3.2. *Свёрточные нейросети (LeCun et al., 1998) — для последовательных вычислений*
   3.3. *Работа Шорохова (2024) — архитектуры на основе CRR*
4. Выявление нерешённых задач и обоснование выбора направления
   4.1. Открытые проблемы в исследуемой области
   4.2. Обоснование выбранного подхода
   4.3. Постановка задач собственного исследования
5. Список литературы

1. Введение в обзор

Обоснование актуальности темы оценки опционов

Одной из фундаментальных задач финансовой инженерии является определение справедливой стоимости производных финансовых инструментов (деривативов). Среди всех классов деривативов особое место занимают опционы — контракты, предоставляющие право, но не обязанность, совершить покупку или продажу базового актива в будущем по заранее оговорённой цене [2, 3]. Корректная оценка опционов критически важна для управления рыночными и кредитными рисками, формирования инвестиционных стратегий и обеспечения стабильности финансовых институтов.

Классическим подходом к ценообразованию опционов является модель Блэка–Шоулза–Мертона [2, 3], которая даёт аналитическое решение для европейских опционов, но не позволяет точно оценивать американские опционы, допускающие досрочное исполнение. В последнем случае широкое распространение получили численные методы: биномиальные деревья [4], метод конечных разностей [5], метод Монте-Карло [6]. Однако эти методы обладают ограничениями с точки зрения вычислительной сложности, особенно при увеличении числа шагов дискретизации, а также в моделях локальной волатильности, где волатильность зависит от времени и цены базового актива [11, 12].

В последние годы наблюдается активное применение методов глубокого обучения для решения задач финансового моделирования [7]. Нейросетевые подходы позволяют аппроксимировать функции ценообразования без явного задания аналитической формы, обучаясь на синтезированных или рыночных данных. Это открывает перспективы для создания гибридных моделей, сочетающих классические финансовые теории с вычислительной мощностью современных нейросетевых архитектур.

Краткая характеристика рассматриваемой области

Настоящий обзор посвящён анализу подходов к оценке американских опционов пут с использованием нейросетевых архитектур, построенных на основе биномиальной модели Кокса–Росса–Рубинштейна (CRR) [4]. Такой выбор обусловлен рядом факторов. Во-первых, биномиальное дерево CRR является наглядным и интуитивно понятным методом, позволяющим учесть возможность досрочного исполнения американских опционов. Во-вторых, структура обратного хода в биномиальном дереве естественным образом отображается на последовательность слоёв нейронной сети, где полносвязный слой с ReLU-активацией моделирует терминальные условия, а свёрточные или maxout-слои воспроизводят дисконтирование ожидаемой стоимости с учётом выбора оптимальной стратегии [1].

В обзоре рассматриваются ключевые работы, заложившие основу применения нейронных сетей в ценообразовании опционов [8, 9], современные обзорные исследования [10], а также последние разработки, в которых архитектуры нейросетей напрямую выводятся из биномиального дерева [1]. Отдельное внимание уделяется методу maxout [13], позволяющему моделировать выбор между удержанием и досрочным исполнением, что является центральным элементом для американских опционов. Дополнительно анализируются возможности верификации разработанных моделей с использованием профессиональных библиотек, таких как QuantLib [15], предоставляющих эталонные численные решения.

Раздел 2. Нейросетевые подходы в ценообразовании опционов

2.1. Ранние работы (Malliaris & Salchenberger, 1993; Hutchinson et al., 1994)

Применение нейронных сетей для оценки опционов имеет достаточно длительную историю, уходящую корнями в начало 1990-х годов, когда вычислительные возможности и теоретическая база машинного обучения только начинали формироваться.

Одной из первых работ в этой области стало исследование Маллиариса и Зальхенбергера [8], в котором авторы предложили использовать нейронную сеть для аппроксимации цены опционов. В работе был реализован трёхслойный перцептрон, обученный на синтетических данных, сгенерированных на основе модели Блэка–Шоулза. Результаты показали, что нейросеть способна воспроизводить теоретические цены с высокой точностью, однако авторы отметили ограниченную способность модели к экстраполяции за пределы обучающей выборки. Данное исследование продемонстрировало принципиальную возможность использования нейронных сетей в задачах финансового ценообразования и заложило основу для последующих работ.

Значительным шагом вперёд стала работа Хатчинсона с соавторами [9], в которой авторы не только применили нейронные сети для оценки опционов, но и исследовали их способность к хеджированию производных финансовых инструментов. Используя архитектуру на основе радиальных базисных функций (RBF) и многослойного перцептрона, Хатчинсон и коллеги показали, что нейросетевые модели могут успешно аппроксимировать нелинейные зависимости между ценой опциона и параметрами базового актива. Важным результатом работы стал вывод о том, что нейронные сети способны эффективно восстанавливать функцию ценообразования при наличии достаточного объёма обучающих данных, что открыло перспективы для использования сетей в условиях, когда аналитическое решение отсутствует или затруднено.

Обе ранние работы обладают общим ограничением: они рассматривали нейронные сети как универсальные аппроксиматоры, не встраивая в архитектуру специфику финансовой модели. Это приводило к необходимости обучения на больших выборках и снижало

интерпретируемость результатов. Тем не менее, именно эти исследования сформировали направление, в котором впоследствии развивались более сложные архитектуры.

2.2. Современные обзоры (Liu et al., 2019)

Систематизация и обобщение накопленного опыта применения нейронных сетей в ценообразовании опционов представлены в обзорной работе Лю с соавторами [10]. Авторы провели всесторонний анализ более чем 60 публикаций, посвящённых нейросетевым подходам, и выделили несколько ключевых направлений.

Во-первых, Лю и соавторы классифицируют существующие работы по типу используемой архитектуры: многослойные перцептроны (MLP), радиальные базисные функции (RBF), рекуррентные нейронные сети (RNN) и свёрточные нейронные сети (CNN). Отмечается, что MLP остаются наиболее распространённым выбором благодаря своей простоте, однако для задач с временной зависимостью более эффективными оказываются RNN, а для обработки многомерных данных — CNN.

Во-вторых, авторы анализируют способы формирования обучающих выборок. Выделяются три подхода: обучение на синтетических данных, сгенерированных аналитическими формулами (например, Блэка–Шоулза), обучение на данных, полученных численными методами (биномиальные деревья, метод конечных разностей), и обучение на реальных рыночных данных. Каждый из подходов имеет свои преимущества и недостатки: синтетические данные обеспечивают точную эталонную разметку, но не учитывают реальную рыночную динамику; реальные данные позволяют учесть фактические закономерности, но содержат шум и требуют тщательной предобработки.

В-третьих, Лю и соавторы отмечают, что к 2019 году большинство работ было сосредоточено на европейских опционах, а оценка американских

опционов нейросетевыми методами оставалась недостаточно исследованной. Это объясняется необходимостью учёта досрочного исполнения, что требует более сложных архитектур или дополнительных этапов обработки (например, использование метода Лонгстаффа–Шварца в комбинации с нейронными сетями).

2.3. Применение глубокого обучения (Schmidhuber, 2015)

Переход от классических нейронных сетей к методам глубокого обучения ознаменовал новый этап в развитии нейросетевых подходов к финансовому моделированию. Обзорная работа Шмидхубера [7] даёт общую картину развития глубокого обучения, подчёркивая, что увеличение глубины сетей позволяет моделировать более сложные зависимости и достигать более высокой точности на задачах, требующих иерархического представления данных.

В контексте ценообразования опционов глубокое обучение открывает возможности для построения архитектур, которые не просто аппроксимируют функцию цены, но и учитывают внутреннюю структуру финансовой модели. Например, использование свёрточных слоёв позволяет эффективно обрабатывать последовательные представления, характерные для биномиальных деревьев, а применение maxout-слоёв [13] даёт возможность моделировать выбор между альтернативными стратегиями, что является ключевым для американских опционов.

Шмидхубер отмечает, что одним из важнейших достижений глубокого обучения является возможность автоматического извлечения признаков из данных, что снижает потребность в ручной инженерии признаков. В задачах оценки опционов это особенно актуально, поскольку зависимость цены от параметров является сложной и нелинейной.

Кроме того, в работе подчёркивается роль методов оптимизации, таких как Adam. Это особенно важно для финансовых приложений, где требуется высокая точность и воспроизводимость результатов.

Таким образом, к середине 2010-х годов были созданы теоретические и методологические предпосылки для разработки специализированных нейросетевых архитектур, в которых финансовая модель и архитектура нейронной сети образуют единое целое, что и было реализовано в последующих работах, включая исследование Шорохова [1].

Раздел 3. Архитектуры нейросетей, релевантные для задачи

3.1. Maxout Networks (Goodfellow et al., 2013) — обоснование использования maxout-слоёв

Ключевым элементом архитектуры для оценки американских опционов является механизм выбора между двумя альтернативами: удержанием опциона до следующего периода или досрочным исполнением. Математически этот выбор описывается операцией максимума, что делает maxout-слои естественным кандидатом для реализации такой логики в нейросетевом базисе.

Работа Гудфеллоу с соавторами [13], в которой была предложена архитектура Maxout Networks, представляет собой значительный вклад в развитие методов глубокого обучения. Авторы вводят новый тип активационной функции — maxout, которая вычисляет максимум по нескольким аффинным преобразованиям входного вектора. В отличие от традиционных функций активации (ReLU, sigmoid, tanh), maxout не имеет фиксированной формы и способна аппроксимировать любую выпуклую функцию, что делает её особенно гибкой для моделирования сложных зависимостей.

Важным свойством maxout-слоёв является их способность к обучению на основе данных: параметры аффинных преобразований подстраиваются в процессе обучения, что позволяет сети адаптироваться к специфике конкретной задачи. В контексте оценки американских опционов это свойство позволяет моделировать не только стандартную биномиальную динамику, но и более сложные сценарии, например, при использовании локальной волатильности.

Кроме того, Гудфеллоу и соавторы показывают, что maxout-слои обладают преимуществами с точки зрения оптимизации: они менее подвержены проблеме «исчезающих градиентов» и позволяют обучать более глубокие сети. Это особенно важно для архитектур с большим числом периодов n, когда глубина сети может достигать десятков слоёв.

В рассматриваемой задаче maxout-слой применяется к двум величинам: результату свёртки выхода предыдущего слоя (что соответствует дисконтированной ожидаемой стоимости при удержании опциона) и линейному преобразованию страйка (что соответствует стоимости досрочного исполнения). Таким образом, maxout-слой естественным образом реализует правило из биномиальной модели.

3.2. Свёрточные нейросети (LeCun et al., 1998) — для последовательных вычислений

Применение свёрточных нейронных сетей (CNN) для задач, связанных с последовательной обработкой данных, имеет давнюю историю, восходящую к фундаментальным работам Яна Лекуна и его соавторов [14]. Изначально разработанные для задач распознавания образов, свёрточные сети продемонстрировали высокую эффективность при обработке структур, обладающих свойством локальной связности.

В контексте биномиальной модели CRR свёрточные слои с фильтром размера 2 оказываются идеальным инструментом для реализации

обратного хода по дереву. Как показано в работе Шорохова [1], операция линейной свёртки вектора, содержащего стоимости опциона в узлах дерева на уровне i+1, с фильтром $W \in R^2$ в точности соответствует дисконтированию ожидаемой стоимости опциона на предыдущем уровне i. Это наблюдение имеет глубокий математический смысл: свёртка позволяет компактно представить операцию переноса информации с одного временного слоя на другой, сохраняя при этом структуру биномиального дерева.

Преимущества использования свёрточных слоёв для данной задачи многообразны. Во-первых, они обеспечивают естественную редукцию размерности: каждый свёрточный слой уменьшает длину вектора на единицу, что соответствует переходу от уровня i+1 к уровню i. Во-вторых, использование общего фильтра W для всех слоёв соответствует тому факту, что вероятности перехода π_u и π_d и дисконтирующий множитель e^{-rdt} не зависят от номера временного слоя в модели CRR с постоянной волатильностью. В-третьих, свёрточные слои обладают высокой вычислительной эффективностью, так как реализуются в виде оптимизированных операций, поддерживаемых аппаратным ускорением (GPU).

3.3. Работа Шорохова (2024) — архитектуры на основе CRR

Ключевым источником, непосредственно определяющим архитектурные решения для данной НИР, является работа Шорохова С.Г. [1], опубликованная в 2024 году. В этой работе автор предлагает два типа нейросетевых архитектур для оценки опционов пут, основанных на биномиальной модели CRR.

Для европейских опционов пут Шорохов предлагает архитектуру, состоящую из:

- Входного слоя, принимающего цену-страйк K;

- Первого скрытого слоя — полносвязного с функцией активации ReLU, имеющего n+1 нейрон;

- Последовательности из n свёрточных слоёв с фильтром размера 2 и тождественной функцией активации;

- Выходного слоя, формирующего скалярную цену опциона.

В работе доказывается (Теорема 1), что при определённом выборе весов (единичный вектор для полносвязного слоя, смещения, равные отрицательным ценам базового актива в листьях дерева, и фильтр W, вычисляемый по формуле) выход сети в точности совпадает с ценой европейского опциона, полученной по модели CRR.

Для американских опционов пут архитектура модифицируется с учётом возможности досрочного исполнения. Ключевые отличия:

- Вместо свёрточных слоёв используются maxout-слои;

- Каждый maxout-слой принимает два входа: результат свёртки выхода предыдущего слоя и линейное преобразование входного значения K;

- Веса линейных преобразований w^i устанавливаются единичными, а смещения b^i — равными отрицательным ценам базового актива на соответствующем уровне дерева.

В Теореме 2 доказывается, что при такой настройке выход сети совпадает с ценой американского опциона пут, вычисленной по модели CRR.

Важным результатом работы является также возможность редукции архитектуры для европейского опциона к двухслойной сети (Замечание 1), что снижает вычислительную сложность и упрощает анализ.

Работа Шорохова [1] предоставляет не только теоретическое обоснование, но и экспериментальное подтверждение работоспособности предложенных архитектур, включая сравнение с формулой Блэка–Шоулза

и классической реализацией CRR. Полученные результаты демонстрируют, что нейросеть, обученная на ценах Блэка–Шоулза, в действительности воспроизводит цены CRR, что объясняется структурой архитектуры.

Таким образом, именно работа [1] является основой для настоящего исследования, в котором предлагается не только воспроизвести предложенные архитектуры, но и расширить экспериментальную базу, включив верификацию с использованием библиотеки QuantLib [15] и анализ поведения моделей при варьировании гиперпараметров.

Раздел 4. Выявление нерешённых задач и обоснование выбора направления

4.1. Открытые проблемы в исследуемой области

Анализ рассмотренных источников позволяет выявить ряд проблем, остающихся нерешёнными или недостаточно изученными в современной литературе по нейросетевой оценке опционов.

Во-первых, верификация нейросетевых моделей для американских опционов представляет собой нетривиальную задачу. В работе Шорохова [1] основное внимание уделено европейским опционам, для которых существует аналитическое решение Блэка–Шоулза, выступающее в роли эталона. Для американских же опционов, не имеющих замкнутой аналитической формулы, в качестве эталона использовалась реализация биномиального дерева CRR, встроенная в тот же программный комплекс. Однако такая верификация не является независимой, поскольку нейросетевая архитектура и эталонная модель реализованы одним автором и потенциально могут содержать систематические ошибки.

Во-вторых, отсутствие сравнения с профессиональными финансовыми библиотеками является существенным пробелом. В современной финансовой инженерии стандартом де-факто является библиотека QuantLib [15], представляющая собой широко верифицированный инструмент для оценки широкого спектра финансовых инструментов, включая американские опционы. Отсутствие в литературе сравнения нейросетевых архитектур с эталонными реализациями из QuantLib снижает убедительность полученных результатов и затрудняет их практическое применение.

В-третьих, исследование сходимости и устойчивости нейросетевых архитектур при изменении числа периодов n и гиперпараметров обучения остаётся фрагментарным. В работе [1] эксперименты проводились только для n = 9, что не позволяет сделать выводы о поведении модели при увеличении глубины биномиального дерева, когда точность CRR возрастает, но вычислительная сложность также растёт.

В-четвёртых, экстраполяционные способности нейросетей, обученных на ценах CRR, за пределы диапазона страйков, использованного при обучении, практически не исследованы. Между тем, для практического применения важно понимать, насколько корректно модель ведёт себя при экстремальных значениях цены исполнения, особенно в условиях ограниченного объёма рыночных данных.

4.2. Обоснование выбранного подхода

Несмотря на указанные ограничения, архитектура нейронной сети на основе биномиального дерева CRR [1] обладает рядом существенных преимуществ, обусловливающих её выбор в качестве основы для настоящего исследования.

Во-первых, интерпретируемость является ключевым достоинством подхода. В отличие от стандартных нейросетей, работающих как «чёрный

ящик», предложенная архитектура имеет чёткую финансовую интерпретацию: каждый слой соответствует определённому шагу обратного хода в биномиальном дереве, а веса слоёв имеют экономический смысл (вероятности перехода, дисконтирующие множители). Это позволяет анализировать поведение сети и выявлять причины возможных отклонений.

Во-вторых, эффективное использование структурного знания о модели CRR позволяет значительно сократить объём обучающей выборки и ускорить сходимость. В предельном случае, при точной настройке весов согласно теоремам 1 и 2, сеть воспроизводит цены CRR без обучения. Это свойство делает архитектуру идеальной для задач, где требуется быстрое переобучение при изменении параметров рынка.

В-третьих, архитектурная простота — использование только полносвязных, свёрточных и maxout-слоёв — обеспечивает высокую вычислительную эффективность как на этапе обучения, так и на этапе инференса. Это особенно важно для практических приложений, где требуется оперативная оценка большого числа опционных контрактов.

В-четвёртых, модульность архитектуры позволяет легко модифицировать её для учёта более сложных факторов: дивидендов, стохастической волатильности или локальной волатильности. В частности, замена постоянной волатильности σ на функцию $\sigma(S, t)$ может быть реализована путём соответствующей модификации весов свёрточных слоёв.

4.3. Постановка задач собственного исследования

На основе проведённого анализа и выявленных нерешённых проблем формулируются следующие задачи собственного исследования:

1. Реализация нейросетевой архитектуры на основе CRR для оценки американских опционов пут с использованием фреймворка PyTorch, обеспечивающего гибкость и производительность.

2. Верификация разработанной модели с использованием профессиональной библиотеки QuantLib [15] как независимого эталона. Для этого планируется:

- Реализовать расчёт цен американских опционов пут с помощью QuantLib при различных параметрах (S_0, K, T, r, σ);
- Сравнить результаты нейросетевой модели с эталонными значениями QuantLib;
- Оценить точность аппроксимации с использованием метрик MAE и RMSE.

3. Исследование сходимости и устойчивости модели при изменении числа периодов n (5, 9, 15, 20, 30, 50) для выявления оптимального баланса между точностью и вычислительной сложностью.

4. Анализ экстраполяционных способностей модели на диапазоне страйков K, выходящем за пределы обучающей выборки ([0.1, 0.9] против обучающего диапазона [0.25, 0.75]).

5. Сравнение эффективности нейросетевого подхода с классическими методами (биномиальное дерево CRR) по критериям:

- Точность оценки (сравнение с эталонными QuantLib-значениями);
- Вычислительное время (на обученной модели vs. на биномиальном дереве);
- Объём требуемых вычислительных ресурсов.

6. Документирование разработанного программного комплекса и размещение его в открытом репозитории GitHub для обеспечения воспроизводимости результатов и возможности дальнейшего развития.

Решение указанных задач позволит не только подтвердить теоретические положения работы [1], но и получить новые экспериментальные данные, расширяющие понимание возможностей и ограничений нейросетевых архитектур на основе биномиального дерева для оценки американских опционов.

Список литературы

1. Шорохов С.Г. Оценка финансовых деривативов нейронной сетью на основе биномиального дерева // International Journal of Open Information Technologies. – 2024. – Т. 12, № 5. – С. 108–114.

2. Black F., Scholes M. The Pricing of Options and Corporate Liabilities // Journal of Political Economy. – 1973. – Vol. 81. – P. 637–654.

3. Merton R.C. Theory of Rational Option Pricing // The Bell Journal of Economics and Management Science. – 1973. – Vol. 4. – P. 141–183.

4. Cox J.C., Ross S.A., Rubinstein M. Option pricing: A simplified approach // Journal of Financial Economics. – 1979. – Vol. 7, No. 3. – P. 229–263.

5. Schwartz E. The Valuation of Warrants: Implementing a New Approach // Journal of Financial Economics. – 1977. – Vol. 4. – P. 79–94.

6. Boyle P. Options: A Monte Carlo Approach // Journal of Financial Economics. – 1977. – Vol. 4, No. 3. – P. 323–338.

7. Schmidhuber J. Deep learning in neural networks: An overview // Neural Networks. – 2015. – Vol. 61. – P. 85–117.

8. Malliaris M., Salchenberger L. A neural network model for estimating option prices // Applied Intelligence. – 1993. – Vol. 3, No. 3. – P. 193–206.

9. Hutchinson J.M., Lo A.W., Poggio T. A nonparametric approach to pricing and hedging derivative securities via learning networks // Journal of Finance. – 1994. – Vol. 49, No. 3. – P. 851–889.

10. Liu S., Oosterlee C.W., Bohte S.M. Pricing Options and Computing Implied Volatilities using Neural Networks // Risks. – 2019. – Vol. 7, No. 1. – P. 16.

11. Dupire B. Pricing with a smile // Risk Magazine. – 1994. – Vol. 7, No. 1. – P. 18–20.

12. Shorokhov S. On Deep Learning for Option Pricing in Local Volatility Models // Proceedings of the 9th International Conference "Distributed Computing and Grid Technologies in Science and Education" (GRID’2021)

13. Goodfellow I., Warde-Farley D., Mirza M., Courville A., Bengio Y. Maxout Networks // Proceedings of the 30th International Conference on Machine Learning. – 2013. – P. 1319–1327.

14. LeCun Y., Bottou L., Bengio Y., Haffner P. Gradient-based learning applied to document recognition // Proceedings of the IEEE. – 1998. – Vol. 86, No. 11. – P. 2278–2324.

15. QuantLib Python Documentation [Электронный ресурс]. – Режим доступа: https://quantlib-python-docs.readthedocs.io/ (дата обращения: 23.03.2026).